Léxico e sintaxe da linguagem Ya!

A linguagem Ya! obedece às seguintes especificações:

- Um programa é uma sequência de declarações;
- Todas as instruções são terminadas por ponto e vírgula (;)
- Uma declaração pode ter os seguintes formatos (exemplos):
 - i: int (declaração de variável)
 - i: int = 1 (declaração com valor de inicialização)
 - i,j,k: int = 1 (declaração múltipla com valor de inicialização todas as variáveis ficam com o mesmo valor)
 - f(): int { <corpo> } (declaração de função)
 - f(a: int, b: bool): int { <corpo> } (função com argumentos)
 - define Nome Tipo (declaração de novo tipo)
- Os tipos pré-definidos são os seguintes:
 - int
 - float
 - string
 - bool
 - Tipo[IntExp] (array com elementos do tipo Tipo)
 - void (tipo para funções sem valor de retorno procedimentos)
- Os literais têm o formato "habitual":
 - Inteiros (1; 30; 5000)
 - Floats (1.2; 0.1; .23; .22e-20)
 - Strings ("hello, world!"; "1.2")
 - Bools (true; false)
- · Expressões binárias:
 - +, -, *, / (int, float)
 - mod, ^ (int, float)
 - ==, != (int, float, bool, string e arrays)
 - <, >, <=, >= (int, float)
 - and, or (bool)

- Expressões unárias:
 - (valor negativo)
 - not (negação booleana)
- Afectações também são expressões:

```
-a = 1

-a = b = c = 1

-a[20] = b[i=2] = 3 - x
```

- O corpo de uma função é constituído por statements. Statements podem ser:
 - Declarações (de variáveis locais, não existem declarações de funções dentro de funções);
 - Expressões (caso especial para afectações, outras expressões não produzem código "interessante" mas podem ser aceites);
 - Instrução de retorno (return Exp)
 - Condicionais:

```
* if BoolExp then { <corpo> }
  * if BoolExp then { <corpo> } else { <corpo> }
- Ciclos (while BoolExp do { <corpo> })
```

- O corpo dos ciclos dos ciclos e condicionais é semelhante ao das funções.
- Um ciclo pode ser forçado a terminar com a instrução break, ou forçado a passar à próxima iteração, com a instrução next (equivalente ao continue do C ou Java).

Palavras reservadas e símbolos

```
; "()[]{}.,:=
+-*/^
== < > <= >= !=
mod and or not
int float string bool void
```

• define if then else while do

• return break next

Funções pré-definidas (parte da "biblioteca" do Ya!)

- print(Exp) → mostra o resultado de Exp no ecrã
- ullet input(lvalue) o guarda um valor escrito no teclado em lvalue (tendo em conta o tipo do lvalue)

TRADUÇÃO APT \rightarrow RI

- O Para cada nó da APT geram-se nós de RI
- Levantam-se algumas questões:
 - Será que um nó do tipo expressão na APT deverá ser representado por um nó do tipo expressão na RI?
 - Acessos a variáveis, encaradas como endereços de memória.
 - Variáveis locais: MEM(BINOP(+, TEMP(fp), CONST(k)))
 - Variáveis externas: MEM(BINOP(+, LABEL(DISPLAY), CONST(SCOPE)))
 - Isto gera sempre um LOAD ou um STORE
 - No caso de arrays ou structs, o princípio é o mesmo, mas as expressões serão mais complexas, pois terão de incluir o cálculo do endereco como uma base e um deslocamento.
 - Declarações
 - Alocação de espaço na stack frame
 - Inicialização de variáveis gera instruções RI para colocar o valor inicial na zona de memória correspondente da stack frame

TRADU ÇÃO APT ightarrow RI

- O Declarações de função
 - Produção de código específico para entrada (prólogo) e saída (epílogo) da função
 - Prólogo
 - Definição de uma label para a função
 - Ajuste do *stack pointer*, suficiente para acomodar as variáveis locais e temporárias: no fundo, o espaço para o RA.
 - Instruções para guardar o contexto que for necessário no RA: guardar os registos *callee-saved*; ajustar o *static link* (via fp e ajuste do *display*)
 - Corpo da função
 - Epílogo
 - Guardar o valor de retorno no local estipulado
 - Repor os registos callee-saved
 - Repor o static link
 - Repor o stack pointer
 - Salto para o *return address*, efectivando o regresso à função chamadora

STATIC LINK, DYNAMIC LINK

Em linguagens com procedimentos imbricados, como referir os frame pointers das funções de nível superior?

- O Mecanismo de DISPLAY
 - Vector (array) global de apontadores (endereços) para o registo de activação mais recente, indexado pelo nível lexical dos procedimentos/funcões.
 - Estritamente necessário quando a linguagem permite declarar procedimentos imbricados.
 - Mas também dá jeito para referir contextos superiores (e.g., variáveis globais em Ya!)
- Em alternativa, podemos usar dynamic linking, onde se usa a cadeia de referências de old fps

ÁRVORES CANÓNICAS

REGRAS PARA REESCRITA

- Objectivo: tornar a RI mais próxima de arquitecturas reais
- Método: transformações simples ao nível dos nós
 - CJUMP: pode saltar para dois endereços distintos; em máquinas reais, apenas se salta num dos casos, continuando para a próxima instrução no outro caso;
 - Os nós ESEQ dentro de expressões são inconvenientes, porque o resultado poderá ser diferente consoante a ordem de avaliação das sub-árvores;
 - Nós CALL dentro de expressões sofrem do mesmo problema;
 - Nós CALL dentro de outros nós CALL dão problemas se a convenção de chamada impuser a colocação dos parâmetros formais em registos específicos.
- O Uma árvore canónica goza de duas propriedades:
 - 1. Não contém ESEQs dentro de SEQs
 - O pai de um CALL é sempre um EXP(...) ou um MOVE(TEMP(t), ...)

REGRAS PARA TRANSFORMAÇÕES (1)

TRANSFORMAÇÕES

- ESEQ: mover os nós para "cima", o mais possível, até poderem ser transformados em nós SEQ (na prática, transformar a árvore numa lista)
- Elevação dos nós CALL: reescrever de forma a que um CALL dentro de outro CALL passe a ser um ESEQ que é avaliado antes do CALL superior, com o seu resultado guardado num temporário.
- CJUMPs: reordenar as sequências de instruções construídas anteriormente, de forma a garantir que um CJUMP é imediatamente seguido pela sequência que começa no label referido no false do CJUMP
- \bigcirc ESEQ(s1, ESEQ(s2, e)) \rightarrow ESEQ(SEQ(s1, s2), e)
- \bigcirc BINOP(op, ESEQ(s, e1), e2) \rightarrow ESEQ(s, BINOP(op, e1, e2))
- \bigcirc MEM(ESEQ(s, e)) \rightarrow ESEQ(s, MEM(e))
- \bigcirc JUMP(ESEQ(s, e)) \rightarrow SEQ(s, JUMP(e))
- O CJUMP(op, ESEQ(s, e1), e2, t, f) \rightarrow SEQ(s, CJUMP(op, e1, e2, t, f))

REGRAS PARA TRANSFORMAÇÕES (2)

REGRAS PARA TRANSFORMAÇÕES (3)

- O BINOP(op, e1, ESEQ(s, e2)) \rightarrow ESEQ(MOVE(TEMP(t), e1), ESEQ(s, BINOP(op, TEMP(t), e2))) \rightarrow ESEQ(SEQ(MOVE(TEMP(t), e1), s), BINOP(op, TEMP(t), e2)))
- O CJUMP(op, e1, ESEQ(s, e2), 11, 12) \rightarrow SEQ(MOVE(TEMP(t), e1), SEQ(s, CJUMP(op, TEMP(t), e2, 11, 12)))
- \bigcirc BINOP(op, e1, ESEQ(s, e2)) \rightarrow ESEQ(s, BINOP(op, e1, e2))
- O CJUMP(op, e1, ESEQ(s, e2), 11, 12) \rightarrow SEQ(op, e1, e2, 11, 12)

(Nestes dois casos, apenas se s e e1 comutarem)

BLOCOS BÁSICOS

- O Reordenar as sequências de instruções, de forma a garantir que uma sequência que termina num CJUMP seja imediatamente seguida pela sequência que começa pelo label referido no false do CJUMP
- O Análise do fluxo de controlo do programa: observa-se a RI disponível, ignorando tudo o que não forem labels nem saltos.
- O Um bloco básico é uma sequência de instruções em que:
 - A primeira é um LABEL
 - o A última é um JUMP ou um CJUMP
 - o Não há nenhum outro LABEL, JUMP ou CJUMP
- O A divisão em blocos básicos pode resultar em qualquer ordem para o programa, que o significado será o mesmo

TRAÇOS

- O Dado um programa dividido em blocos básicos, a forma como eles se ordenam relativamente uns aos outros pode influir no código produzido.
- O Chama-se um traço a uma sequência de blocos básicos que reflecte o programa original
- Construímos um conjunto de traços que cubra todo o programa (i.e., que inclua todos os blocos básicos). Note-se que o
- Se o bloco termina num JUMP, não há dúvida quanto ao que fazer
- O Se termina num CJUMP, podemos optar por construir um traço que siga por qualquer uma das saídas. Por conveniência:
 - Um CJUMP seguido pela sua label false fica inalterado;
 - o Num CJUMP seguido pela sua label true, trocam-se os labels true e false e inverte-se a condição
 - o Num CJUMP que não é seguido de nenhuma das suas labels, cria-se um bloco básico artificial (que o segue) com duas instruções: um LABEL e um JUMP.

IVENESS ANALYSIS

GRAFO DE FLUXO

- O Construímos um grafo de fluxo
- O Variável "viva": o seu valor vai ser usado no futuro
- Análise faz-se do futuro para o passado.
- O Se a variável é usada num nó, significa que está viva à entrada desse nó

Programa

b if a < N goto L1

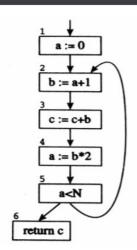
0

return

a

GRAFO DE FLUXO

LIVENESS ANALYSIS (2)



- \bigcirc b está viva em $\{2 \rightarrow 3\}$ e $\{3 \rightarrow 4\}$
- \bigcirc a está viva em $\{1 \rightarrow 2\}$ e $\{4 \rightarrow 5\}$
- o c está viva desde o início até ao fim. (talvez seja um argumento da função?)
- O Se c não é um argumento, então detectámos uma variável não inicializada!

- O Problema NP-Completo
- Tal como coloração de grafos...
- Usamos o algoritmo BSSS que dá uma boa aproximação, em tempo linear
- (Build, Simplify, Spill and Select)

- O Criar o grafo de interferências
- Cada temporário representa um vértice do grafo
- Temporários que estão vivos em simultâneo têm um arco a ligá-los

ALGORITMO BSSS - SELECT

- Retiram-se, um a um, os vértices da pilha e atribui-se uma cor não usada em nenhum "vizinho"
- Quando retiramos um vértice colocado na pilha sob ameaça de spilling, pode haver ainda cor para ele, pois apesar de ter mais do que K vizinhos, alguns deles podem ter cores iguais.
- Se n\u00e3o houver cor dispon\u00edvel, marcamos esse v\u00e9rtice como spilled e continuamos o Select.
- Se ficámos com temporários spilled, temos de reescrever o programa de forma a que esses temporários se transformem em vários temporários (cada um), com um tempo de vida mais curto (vão ser transferidos de e para a memória).
- Começar de novo, pois estes novos temporários podem ter influência no resto do grafo.
- Normalmente, o processo termina em uma ou duas iterações (quando o Simplify termina sem dar origem a spills.

ALGORITMO BSSS - SIMPLIFY, SPILL

- K = número de registos disponíveis = número de cores do grafo
- Recursivamente, removemos do grafo os vértices com menos de K arcos e colocamo-los numa pilha.
- Se num momento do passo anterior o grafo só tem vértices de grau >= K, escolhemos um desses nós para spilling, removendo-o para a pilha. Continuar com a simplificação.

- Quando no grafo de interferências não há arco entre a origem e o destino de um move, as variáveis podem ser aglutinadas numa só, eliminando a necessidade do move.
- Agressivamente, quaisquer duas variáveis que não têm um arco entre elas podem ser aglutinadas.
- É preciso cuidado, pois a variável resultante vai ter a conjunção dos arcos das duas que lhe deram origem (podemos precisar de mais spills...)
- O Não se faz em compile-time
- São procedimentos que se linkam ao executável, para correr em run-time
- O Vários algoritmos standard
 - Mark-&-sweep
 - Copying collection
 - Generational collection
 - Incremental collection
 - o Etc.

MARK-AND-SWEEP (MARK)

MARK-AND-SWEEP (SWEEP)

```
function DFS(x)

if x is a pointer to the heap

if *x is not marked

mark x

for each field f(i) of record x

DFS(x.f(i))
```

```
let p = first heap address
while p < last heap address
if *p is marked
unmark p
else let f(i) = first field in p
p.f(i) = freelist
freelist = p
p = p + sizeof(*p)
```

OUTRAS OPTIMIZAÇÕES (1)

O Remoção de loads e stores redundantes

```
MOVE RO, a
MOVE a, RO
```

Código inacessível

```
#define DEBUG 0

2 . . .

3 if (DEBUG) {

4 . . .

5
```

OUTRAS OPTIMIZAÇÕES (2)

Saltos para saltos

```
goto L1

L1: goto L2

L2:
```

O Simplificação algébrica

```
x := x + 0

/* ou */

x := a * 0
```

Universidade de Évora

Compiladores

1ª Frequência - Correcção

(1) 1. Considere o seguinte conjunto de números de vírgula flutuante:

Qual das seguintes expressões regulares identifica números (literais) do tipo dos que pertencem ao conjunto? (considere a notação do flex)

- A. [0-9]\.[0-9]*[Ee]?[0-9]+
- B. [0-9]?\.[0-9]+([Ee]?[0-9]+)*
- C. [0-9]*\.[0-9]+([Ee][+-]?[0-9]+)?
- D. [0-9]+(\.)?[0-9]*[Ee+-]?[0-9]?
- Usando a questão anterior como exemplo, explique como se processam, em termos de compilação, os casos em que:
- (1) (a) o número é negativo (e.g., {-1.0, -.365, -0.234E25, -0.123e-10, -.23e+15}).

Solução: Os números são tokens sem sinal. O sinal de menos é um token. Na gramática há uma regra para o menos (unário), que determina que um sinal de menos antes de algo é uma operação unária. Resumindo, os números negativos são tratados como operações unárias cujo operador é -.

(Nota: geralmente, é feito o mesmo para o sinal de +, mas este pode ser ignorado quando se gera a APT).

(0.75) (b) aparecem vários sinais (e.g., 3.5 - -2.1).

Solução: Neste caso temos uma operação unária de - aplicada ao segundo número e uma operação binária de - entre dois argumentos. Resumindo, temos uma subtracção (normal) entre uma expressão que é um literal float e outra expressão que é uma operação unária de - aplicada a outra expressão que é outro literal float.

- Para as seguintes linhas de código, proponha uma representação para a sintaxe abstracta e desenhe as APTs respectivas:
- (1.5) (a) a = f(x);

Solução: Para este exemplo, precisamos de 3 tipos de nós na sintaxe abstracta:

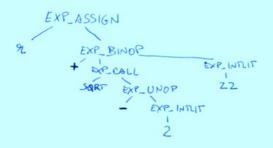
- exp_assign(ID, EXP)
- exp_call(ID, ARG) (simplificamos e assumimos que só há 1 argumento)
- exp_id(ID)

(1.5) (b) r = sqrt(-2) + 22;

Página 1 de 5

 ${\bf Solução:}\,$ Acrescentamos alguns nós à sintaxe abstracta:

- exp_binop(OP, EXP, EXP)
- exp_unop(OP, EXP)
- exp_intlit(NUM)



(1.5) (c) while (n<10) do { print(n); };

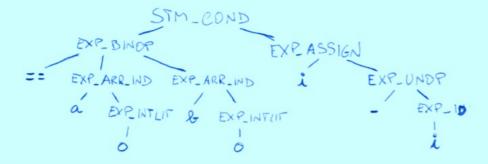
Solução: Para este excerto, já temos quase tudo, apenas nos falta um nó para o ciclo:

• stm_loop(COND, BODY) (vamos assumir que o body tem só uma instrução)

$$(1.5) \qquad (d) \ \text{if a[0] == b[0] then { i = -i };}$$

Solução: Agora temos um condicional (igual ao ciclo, para este exemplo até podemos ignorar o *iffalse branch*), mas a maior novidade é o acesso a índices de array:

- stm_cond(COND, IFTRUE)
- exp_arr_ind(ID, EXP)



 Considere o processo de compilação de um determinado programa. Na fase da análise semântica, obteve-se a seguinte evolução da Symbol Table:

	id	type	args	
f	4507777	float	int, int	
a		int(arg)		EM
b		int(arg)		
i		int		
Ir		float		

id	type	args	
f	float	int, int	
g	int	float	
a	float(arg)		
i	int		

. [id	type	args
	f	float	int, int
19	g	int	float
	0	int	
ı	main	void	void
	t	string	

(1)

(a) A Symbol Table apresentada ainda sofrerá alterações até ao fim da análise semântica? Justifique.

Solução: Sofrerá pelo menos uma alteração: ao chegar ao fim da sub-árvore da função main(), será chamada a função drop_environment(), que remove o scope de nível 2 da Symbol Table (ou seja, a variável t vai desaparecer).

Por outro lado, nada sabemos sobre o código do programa nem sobre a linguagem, consoante os quais ainda podemos ter:

- mais variáveis na função main()
- · mais variáveis globais depois da função main()
- · mais funções declaradas após a função main()
- .5) (b) Proponha um excerto de programa que possa ter dado origem à Symbol Table apresentada.

Solução: Basta um simples exemplo, mesmo sem código "executável":

```
f(a:int, b:int) : float {
    i: int;
    r: float;
}
g(a:float) : int {
    i: int;
}
o: int;
main() : void {
    t: string;
}
```

Note-se que a variável o é global, pois não aparece dentro de nenhum contexto local na Symbol Table.

5. Considere o seguinte programa em Ya!:

```
factrec (n: int) : int {
   a,b: float;

if n == 1 then { b = 1; }
   else {
   a = n - 1;
   b = n * factrec(a);
};
   return b;
};

main () : void {
   a: int[10];
   print(factrec(3));
};
};
```

(1.5) (a) Suponha que se introduz uma nova linha de código entre as linhas 7 e 8: a[1] = 0. Que tipo de erro estamos a introduzir? Justifique em 10 palavras ou menos.

Solução: Estamos a introduzir um erro semântico, pois apesar de a sintaxe estar correcta, a variável a não é de um tipo indexável.

(1.5) (b) Mostre uma representação da Symbol Table, aquando da análise semântica do ramo da APT correspondente ao código da linha 8.

	id	type	args
	factrec		int
	n	int(arg)	
	a	float	
	b	float	
Solução:			

(2) (c) Explique, de forma sucinta, como é feita a distinção entre a variável a da função factrec e a variável a da função main, durante o processo de compilação.

Solução: Na análise semântica, as variáveis ficam em contextos diferentes (nunca coexistem na Symbol Table. Durante a execução, cada uma está num registo de activação diferente.

(1.25) (d) Proponha um desenho para o Registo de Activação da função factrec().

Solução: Uma hipótese, assumindo que o valor da chamada recursiva necessita de um temporário:

Old FP
n
Return Value
Return Address
a
b
templ(factrec(a))

(1.25) (e) Considerando o desenho proposto por si na alínea anterior, dê uma estimativa do espaço máximo ocupado na stack pela função factrec(), assumindo a execução do código da linha 14.

Solução: Aqui basta uma estimativa. Assumindo que a arquitectura de destino é de 32 bits, o RA apresentado (7 words) ocuparia $7 \times 4 = 28$ bytes. Como a chamada vai ser recursiva 2 vezes, o tamanho máximo seriam 84 bytes.

Se não considerarmos a chamada com o argumento 3, então a stack poderá crescer infinitamente (característica das funções recursivas).

(1.25) (f) Suponha agora que alguém implementou um compilador para a linguagem Ya!, do qual não sabemos nada sobre a sua implementação. Ao correr esse compilador sobre o código anterior, obtém-se a seguinte mensagem de erro:

Erro de tipos na linha 7.

Resumidamente, e assumindo que o compilador está bem implementado (com excepção das mensagens de erro não estarem detalhadas), dê uma ideia sobre o que se passa para o erro ter ocorrido.

Solução: Claramente, este compilador não faz a conversão implícita entre int e float... O erro tanto pode ser por estarmos a passar um argumento float à função factrec(), como por estarmos a afectar o resultado de factrec() (int) à variável b (float).